

Legenda das categorias de artista

Cada variante corresponde a uma faixa de cachê (Valor_dia)

G1 - Pequenos Artistas : R0,00aR 9.999,99


G2 - Artistas Médios : R10.000,00aR 49.999,99

G3 - Super Artistas : acima de R\$ 50.000,00


Comparativo das variantes G1, G2 e G3

Variante	Perfil	Categoria_Id	Registros_orig	Registros_final	Features	Valor_medio	R2_treino	R2_teste	MAE_teste	RMSE_teste	Diff_R2
G1	Pequenos Artistas	1	4152	3947	41	5092.4725	0.4471	0.2615	1490.2473	1860.0338	0.1856
G2	Artistas Médios	2	1593	1531	40	24565.161	0.4857	0.0973	7528.7374	9384.9041	0.3884
G3	Super Artistas	3	1267	1153	40	105069.6803	0.4705	-0.0737	47612.1986	59397.6489	0.5442


R² por categoria de artista (treino vs. teste)



MAE no teste (R\$)



RMSE no teste (R\$)



Conclusão — Comparação por categoria de artista

Melhor R^2 de teste: G1 - Pequenos Artistas (0.2615)

Leitura:

- R^2 de teste mais alto => modelo explica melhor o Valor_dia.
- MAE/RMSE menores => erros em reais menores.
- Diferença treino-teste alta => sinal de overfitting.

G1 (Pequenos Artistas): $R^2_{\text{teste}}=0.262$ | MAE=1,490 | RMSE=1,860

G2 (Artistas Médios): $R^2_{\text{teste}}=0.097$ | MAE=7,529 | RMSE=9,385

G3 (Super Artistas): $R^2_{\text{teste}}=-0.074$ | MAE=47,612 | RMSE=59,398

Variante G1 (Pequenos Artistas) — Etapa 1: Exploração

Categoria_Id = 1 | Cachê: R0,00aR 9.999,99 | Dataset_Secretaria_Cultura_SP_varG1.csv

Perfil: Pequenos Artistas

Faixa de cachê (Valor_dia): R0,00aR 9.999,99

Registros: 4,152

Colunas: 8

Período (Ano): 2023 a 2026

Valor_dia médio: R\$ 4,944.56

Valor_dia mediano: R\$ 5,000.00

Valor_dia desvio padrão: R\$ 2,214.71

Valor_dia mínimo: R\$ 73.67

Valor_dia máximo: R\$ 9,999.98

Fornecedores únicos: 1819


Regiões únicas: 32

Zonas únicas: 6

G1 — Pequenos Artistas — Estatísticas descritivas

count	mean	std	min	25%	50%	75%	max
4152.0	6185.23	3749.32	1.0	3454.75	5042.5	9114.5	14205.0
4152.0	2024.3	1.0	2023.0	2023.0	2025.0	2025.0	2026.0
4152.0	6.54	3.16	1.0	4.0	7.0	9.0	12.0
4152.0	2614.33	1865.59	5.0	1068.25	1891.0	3884.0	6841.0
4152.0	4944.56	2214.71	73.67	3300.0	5000.0	7157.14	9999.98
4152.0	14.91	9.75	1.0	7.0	13.0	23.0	32.0
4152.0	3.25	1.44	1.0	2.0	3.0	5.0	6.0
4152.0	1.0	0.0	1.0	1.0	1.0	1.0	1.0

G1 — Pequenos Artistas — Distribuição da variável-alvo Valor_dia



Variante G1 (Pequenos Artistas) — Etapa 2: Detecção de Anomalias

Anomalias IQR: 0

Anomalias K-Means: 205

Anomalias combinadas: 205

Percentual combinado: 4.9%

Regra IQR:


Limite inferior = -2,485.71

Limite superior = 12,942.86


Regra K-Means:

Limiar no percentil 95% = 1.6675

G1 — Pequenos Artistas — Valor_dia COM anomalias



G1 — Pequenos Artistas — Valor_dia SEM anomalias IQR



Variante G1 (Pequenos Artistas) — Etapa 3: Tratamento do Dataset

Registros originais: 4,152

Anomalias removidas: 205

Registros finais: 3,947


Redução: 4.9%

Valor_dia médio após tratamento: R\$ 5,092.47


Valor_dia mediano após tratamento: R\$ 5,000.00

Arquivo limpo: Dataset_Secretaria_Cultura_SP_varG1_tratado.csv

G1 — Pequenos Artistas — Valor_dia ANTES do tratamento



G1 — Pequenos Artistas — Valor_dia DEPOIS do tratamento



G1 — Pequenos Artistas — Resumo da preparação

informacao	valor
Variante	G1
Perfil	Pequenos Artistas
Faixa de cachê	R0,00aR 9.999,99
Categoria_Id	1
Registros de treino	3354
Registros de teste	593
Total de features	41
Target encoding	Fornecedor_Id
One-hot encoding	Regiao_Id, Zona_Id
Padronização	StandardScaler (fit no treino)

Variante G1 (Pequenos Artistas) — Etapa 5: Treinamento

Intercepto: 5,112.64


Número de features: 41

Registros de treino: 3,354

Modelo: `sklearn.linear_model.LinearRegression`

Padronização: `StandardScaler`


G1 — Pequenos Artistas — Top 15 coeficientes da Regressão Linear




G1 — Pequenos Artistas — Métricas: Treino vs. Teste

conjunto	R2	MAE	RMSE
Treino	0.4471	1264.5465	1562.7213
Teste	0.2615	1490.2473	1860.0338


G1 — Pequenos Artistas — Teste: Real vs. Previsto



G1 — Pequenos Artistas — Resíduos vs. Previsto (Teste)



G1 — Pequenos Artistas — Distribuição dos resíduos (Teste)



Variante G1 (Pequenos Artistas) — Diagnóstico Final

Cachê: R0,00aR 9.999,99

R^2 Treino: 0.4471

R^2 Teste: 0.2615

MAE Teste: R\$ 1,490.25

RMSE Teste: R\$ 1,860.03

Diferença R^2 (treino - teste): 0.1856

Variante G2 (Artistas Médios) — Etapa 1: Exploração

Categoria_Id = 2 | Cachê: R10.000,00aR 49.999,99 | Dataset_Secretaria_Cultura_SP_varG2.csv

Perfil: Artistas Médios

Faixa de cachê (Valor_dia): R10.000,00aR 49.999,99

Registros: 1,593

Colunas: 8

Período (Ano): 2023 a 2026

Valor_dia médio: R\$ 24,635.10

Valor_dia mediano: R\$ 24,000.00

Valor_dia desvio padrão: R\$ 10,569.55

Valor_dia mínimo: R\$ 10,000.00

Valor_dia máximo: R\$ 49,950.00

Fornecedores únicos: 856


Regiões únicas: 31

Zonas únicas: 6

G2 — Artistas Médios — Estatísticas descritivas

count	mean	std	min	25%	50%	75%	max
1593.0	7547.94	3763.15	16.0	4125.0	7829.0	10729.0	14250.0
1593.0	2023.92	1.0	2023.0	2023.0	2023.0	2025.0	2026.0
1593.0	6.92	3.1	1.0	5.0	7.0	9.0	12.0
1593.0	3324.85	1856.37	11.0	1820.0	3137.0	4894.0	6831.0
1593.0	24635.1	10569.55	10000.0	15000.0	24000.0	30000.0	49950.0
1593.0	14.63	9.03	1.0	13.0	13.0	17.0	32.0
1593.0	3.24	1.34	1.0	3.0	3.0	3.0	6.0
1593.0	2.0	0.0	2.0	2.0	2.0	2.0	2.0

G2 — Artistas Médios — Distribuição da variável-alvo Valor_dia



Variante G2 (Artistas Médios) — Etapa 2: Detecção de Anomalias

Anomalias IQR: 0

Anomalias K-Means: 62

Anomalias combinadas: 62

Percentual combinado: 3.9%

Regra IQR:


Limite inferior = -7,500.00

Limite superior = 52,500.00


Regra K-Means:

Limiar no percentil 95% = 1.6067

G2 — Artistas Médios — Valor_dia COM anomalias



G2 — Artistas Médios — Valor_dia SEM anomalias IQR



Variante G2 (Artistas Médios) — Etapa 3: Tratamento do Dataset

Registros originais: 1,593

Anomalias removidas: 62

Registros finais: 1,531


Redução: 3.9%

Valor_dia médio após tratamento: R\$ 24,565.16


Valor_dia mediano após tratamento: R\$ 24,000.00

Arquivo limpo: Dataset_Secretaria_Cultura_SP_varG2_tratado.csv

G2 — Artistas Médios — Valor_dia ANTES do tratamento



G2 — Artistas Médios — Valor_dia DEPOIS do tratamento



G2 — Artistas Médios — Resumo da preparação

informacao	valor
Variante	G2
Perfil	Artistas Médios
Faixa de cachê	R10.000,00aR 49.999,99
Categoria_Id	2
Registros de treino	1301
Registros de teste	230
Total de features	40
Target encoding	Fornecedor_Id
One-hot encoding	Regiao_Id, Zona_Id
Padronização	StandardScaler (fit no treino)

Variante G2 (Artistas Médios) — Etapa 5: Treinamento

Intercepto: 24,482.65


Número de features: 40

Registros de treino: 1,301

Modelo: `sklearn.linear_model.LinearRegression`

Padronização: `StandardScaler`


G2 — Artistas Médios — Top 15 coeficientes da Regressão Linear




G2 — Artistas Médios — Métricas: Treino vs. Teste

conjunto	R2	MAE	RMSE
Treino	0.4857	5964.8532	7576.7617
Teste	0.0973	7528.7374	9384.9041


G2 — Artistas Médios — Teste: Real vs. Previsto



G2 — Artistas Médios — Resíduos vs. Previsto (Teste)



G2 — Artistas Médios — Distribuição dos resíduos (Teste)



Variante G2 (Artistas Médios) — Diagnóstico Final

Cachê: R10.000,00aR 49.999,99

R^2 Treino: 0.4857

R^2 Teste: 0.0973

MAE Teste: R\$ 7,528.74

RMSE Teste: R\$ 9,384.90

Diferença R^2 (treino - teste): 0.3884

Variante G3 (Super Artistas) — Etapa 1: Exploração

Categoria_Id = 3 | Cachê: acima de R\$ 50.000,00 | Dataset_Secretaria_Cultura_SP_varG3.csv

Perfil: Super Artistas

Faixa de cachê (Valor_dia): acima de R\$ 50.000,00

Registros: 1,267

Colunas: 8

Período (Ano): 2023 a 2026

Valor_dia médio: R\$ 127,862.22

Valor_dia mediano: R\$ 90,000.00

Valor_dia desvio padrão: R\$ 121,790.02

Valor_dia mínimo: R\$ 50,000.00

Valor_dia máximo: R\$ 2,000,000.00

Fornecedores únicos: 526


Regiões únicas: 31

Zonas únicas: 6

G3 — Super Artistas — Estadísticas descriptivas

count	mean	std	min	25%	50%	75%	max
1267.0	8100.58	3715.56	45.0	4269.0	7961.0	11309.5	14152.0
1267.0	2023.77	0.94	2023.0	2023.0	2023.0	2025.0	2026.0
1267.0	7.6	2.9	1.0	5.0	7.0	10.0	12.0
1267.0	3684.04	1764.4	541.0	1921.0	3884.0	5279.5	6839.0
1267.0	127862.22	121790.02	50000.0	60000.0	90000.0	150000.0	2000000.0
1267.0	13.96	8.33	1.0	13.0	13.0	13.0	32.0
1267.0	3.12	1.22	1.0	3.0	3.0	3.0	6.0
1267.0	3.0	0.0	3.0	3.0	3.0	3.0	3.0

G3 — Super Artistas — Distribuição da variável-alvo Valor_dia



Variante G3 (Super Artistas) — Etapa 2: Detecção de Anomalias

Anomalias IQR: 90

Anomalias K-Means: 64

Anomalias combinadas: 114

Percentual combinado: 9.0%

Regra IQR:


Limite inferior = -75,000.00

Limite superior = 285,000.00


Regra K-Means:

Limiar no percentil 95% = 1.9742

1e6 G3 — Super Artistas — Valor_dia COM anomalies



G3 — Super Artistas — Valor_dia SEM anomalies IQR



Variante G3 (Super Artistas) — Etapa 3: Tratamento do Dataset

Registros originais: 1,267

Anomalias removidas: 114

Registros finais: 1,153


Redução: 9.0%

Valor_dia médio após tratamento: R\$ 105,069.68


Valor_dia mediano após tratamento: R\$ 88,000.00

Arquivo limpo: Dataset_Secretaria_Cultura_SP_varG3_tratado.csv

G3 — Super Artistas — Valor_dia ANTES do tratamento



G3 — Super Artistas — Valor_dia DEPOIS do tratamento



G3 — Super Artistas — Resumo da preparação

informacao	valor
Variante	G3
Perfil	Super Artistas
Faixa de cachê	acima de R\$ 50.000,00
Categoria_Id	3
Registros de treino	980
Registros de teste	173
Total de features	40
Target encoding	Fornecedor_Id
One-hot encoding	Regiao_Id, Zona_Id
Padronização	StandardScaler (fit no treino)

Variante G3 (Super Artistas) — Etapa 5: Treinamento

Intercepto: 105,041.63


Número de features: 40

Registros de treino: 980

Modelo: `sklearn.linear_model.LinearRegression`

Padronização: `StandardScaler`


G3 — Super Artistas — Top 15 coeficientes da Regressão Linear




G3 — Super Artistas — Métricas: Treino vs. Teste

conjunto	R2	MAE	RMSE
Treino	0.4705	30855.274	40055.7037
Teste	-0.0737	47612.1986	59397.6489


G3 — Super Artistas — Teste: Real vs. Previsto



G3 — Super Artistas — Resíduos vs. Previsto (Teste)



G3 — Super Artistas — Distribuição dos resíduos (Teste)



Variante G3 (Super Artistas) — Diagnóstico Final

Cachê: acima de R\$ 50.000,00

R^2 Treino: 0.4705

R^2 Teste: -0.0737

MAE Teste: R\$ 47,612.20

RMSE Teste: R\$ 59,397.65

Diferença R^2 (treino - teste): 0.5442