

Relatório de Projeto Integrador I: Análise e previsão de cachês artísticos culturais – Cidade de São Paulo

1. Introdução e Contextualização do Projeto

Este relatório apresenta os resultados da modelagem preditiva de cachês artísticos e culturais contratados pela municipalidade de São Paulo. O projeto, fundamentado na base de dados da Secretaria Municipal de Cultura (SMC) abrangendo o intervalo de 2017 a 2026, analisa um volume financeiro expressivo que soma aproximadamente R\$ 5,6 bilhões em contratos públicos. O objetivo central reside na estruturação de um pipeline de *Machine Learning* robusto, capaz de conferir previsibilidade e transparência à alocação de recursos públicos no setor cultural.

A evolução estratégica do dataset envolveu uma triagem rigorosa: de um montante inicial superior a 15.000 registros, a limpeza técnica resultou em 14.823 entradas válidas. Visando mitigar o ruído estatístico causado pela heterogeneidade das naturezas contratuais, o escopo foi refinado para o nicho de "Shows e Música", consolidando uma base de 7.016 registros para o treinamento e teste dos modelos.

2. Metodologia e Preparação de Dados

O processo de Extração, Transformação e Carga (ETL) foi implementado em Python, utilizando técnicas de mineração de dados em fontes semiestruturadas (planilhas Excel e arquivos PDF públicos). Um diferencial técnico na higienização dos dados foi a extração de variáveis geográficas via análise textual da "**Cláusula 1**" dos contratos, identificando endereços através de termos-chave como "**rua**" e "**avenida**" para o georreferenciamento dos eventos.

A variável *target* (alvo) foi definida como Valor_dia. Esta normalização (valor total do contrato dividido pela duração do evento) é imperativa para garantir a comparabilidade entre contratações pontuais e contratos de longa duração (semestrais ou anuais), evitando distorções nas métricas de erro.

Para a estruturação do pipeline de dados, foram aplicadas as seguintes transformações:

- **Target Encoding:** Aplicado à variável Fornecedor_Id para lidar com a **alta cardinalidade** dos prestadores de serviço, permitindo que o modelo capture o peso financeiro de cada artista sem incorrer na maldição da dimensionalidade.
- **One-Hot Encoding:** Aplicado às variáveis categóricas Regiao_Id e Zona_Id.

- **Padronização:** Uso do StandardScaler, com o ajuste (*fit*) realizado exclusivamente no conjunto de treino para impedir o vazamento de dados (*data leakage*).

3. Segmentação Estratégica: Variantes G1, G2 e G3

Dada a acentuada assimetria na distribuição dos cachês, o dataset foi segmentado em três perfis distintos de artistas para otimizar o ajuste dos algoritmos:

- **G1 (Pequenos Artistas):** Cachês entre R 0,00 e R 9.999,99. Este grupo é o mais representativo em volume, compondo **59% do total de eventos** no nicho de música (3.947 registros finais).
- **G2 (Artistas Médios):** Cachês entre R 10.000,00 e R 49.999,99. Representa o estrato intermediário de contratações.
- **G3 (Super Artistas):** Cachês superiores a R\$ 50.000,00. Caracteriza-se por alta volatilidade, representando o topo da pirâmide de investimentos culturais.

4. Análise de Desempenho dos Modelos (Regressão Linear)

Abaixo, consolidam-se as métricas de performance obtidas. O indicador Diff_R2 é utilizado como termômetro da capacidade de generalização do modelo (decaimento entre treino e teste).

Variante	Perfil	R ² Treino	R ² Teste	Diff_R2	MAE Teste (R\$)	RMSE Teste (R\$)
G1	Pequenos Artistas	0,4471	0,2615	0,1856	1.490,25	1.860,03
G2	Artistas Médios	0,4857	0,0973	0,3884	7.528,74	9.384,90
G3	Super Artistas	0,4705	-0,0737	0,5442	47.612,20	59.397,65

Diagnóstico de Performance: A premissa de linearidade mostrou-se insuficiente para a complexidade do mercado artístico. Embora o grupo **G1** apresente maior estabilidade, o grupo **G2** exibe um cenário claro de *overfitting*, com um Diff_R2 de 0,3884. O colapso mais severo ocorre no **G3**, cujo R² negativo (-0,0737) indica que o modelo é estatisticamente inferior ao uso da média aritmética como preditor. No G3, o **RMSE de R 59.397,65 representa quase 56% do valor médio do cachê (R 105.069,68)**, evidenciando uma margem de erro inaceitável para aplicações executivas.

5. Diagnóstico de Variáveis e Relevância do Fornecedor

A análise de importância de *features* aponta o Fornecedor_Id como o preditor de maior relevância. Contudo, a **alta cardinalidade e a dispersão (*sparsity*)** dessa variável representam o principal gargalo para a generalização. A base de dados revela uma baixíssima taxa de repetição de artistas, o que impede que modelos lineares aprendam padrões consistentes de precificação.

Temporalmente, observou-se um **pico sazonal significativo em agosto**. Este fenômeno é explicado por fatores ambientais e estratégicos: o aniversário da cidade de São Paulo, que concentra uma densidade maior de eventos e contratações em um curto intervalo temporal, aumentando a variância dos dados nesse período.

6. Conclusões e Recomendações Estratégicas

A falha na convergência dos modelos lineares para os estratos G2 e G3 demonstra que a heterogeneidade do mercado cultural viola as premissas de homocedasticidade exigidas pela regressão linear. A precificação artística não segue uma progressão linear simples, sendo influenciada por fatores de popularidade e exclusividade que a modelagem atual não captura integralmente.

Como próximos passos, recomenda-se:

- **Implementação de Algoritmos Não-Lineares:** Substituição da regressão linear por **Random Forest** e **XGBoost**, que são nativamente aptos a processar relações complexas entre variáveis categóricas de alta cardinalidade.
- **Investigação de Resíduos no G3:** Realizar auditoria matemática nos contratos de alto valor para identificar se o erro preditivo decorre de anomalias genuínas ou variáveis omitidas.
- **Deteção de Anomalias e Fraudes:** Utilizar o pipeline atual para identificar desvios padrão exorbitantes em relação à média de mercado, servindo como ferramenta de auxílio ao *compliance* público.

7. Referências e Contexto Acadêmico

Este documento é o resultado técnico do **Módulo I — 1º Semestre de 2026** do Curso de Especialização em Inteligência Artificial da **PUC-SP**. O projeto foi conduzido sob a metodologia **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), integrando as disciplinas de Programação para IA, Estatística Aplicada e Aprendizado de Máquina Supervisionado.